Introducción al análisis de datos con Python

MINICURSO · DE LOS DATOS CRUDOS A LAS GRÁFICAS

Andrés David Galeano Quintero

Taller práctico en Google Colab con pandas y matplotlib: solo se necesita un navegador y una cuenta de Google.

Noventa minutos: de los datos crudos a las gráficas

A G E N D A

Bloque	Tiempo	Qué haremos
1. Por qué y para qué	0:00 – 0:12	Qué es analizar datos, por qué limpiar y qué tipos de variables hay
2. Tipos de gráficas	0:12 – 0:30	Qué pregunta responde cada gráfica y cómo leerla sin engañarse
3. Taller ETL	0:30 – 1:05	En Colab: extraer, corregir 7 errores y cargar la base de «Pan de Datos»
4. Análisis gráfico	1:05 – 1:22	Cinco gráficas sobre la base limpia, cada una con su pregunta
5. Cierre	1:22 – 1:30	Resumen de métodos, lista de chequeo de limpieza y preguntas

Primero las ideas (30 min); después, 52 min de práctica en el cuaderno (notebook) de Colab y 8 de cierre. Archivos del taller: `[enlace del taller]`

Analizar datos es responder preguntas con evidencia

BLOQUE 1 · POR QUÉ Y PARA QUÉ

1. Una pregunta

Todo empieza con algo que queremos saber: ¿a qué hora se llena la cafetería?, ¿qué materia tiene más reprobados? Sin pregunta, los datos son solo números.

2. Evidencia

Reunimos, limpiamos y resumimos los datos que responden la pregunta: conteos, promedios, tendencias y gráficas.

3. Una decisión

La respuesta sirve para actuar: abrir otra caja en la cafetería, reforzar monitorías o mover un horario.

EN UNA FRASE

Analizar datos es ir de una pregunta a una decisión, apoyados en evidencia.

Los datos bien leídos ya cambiaron decisiones reales

BLOQUE 1 · PARA QUÉ SIRVE

Cólera · Londres, 1854

John Snow registró dónde ocurrían las muertes por cólera y vio que se concentraban alrededor de una bomba de agua de Broad Street. Con esa evidencia, las autoridades retiraron la manija.

Hospitales · Crimea

Florence Nightingale mostró con gráficas que más soldados morían por enfermedades evitables que por heridas de combate. Su análisis impulsó reformas de higiene en los hospitales militares.

Deporte · Oakland, 2002

Con uno de los presupuestos más bajos de las Grandes Ligas, los Oakland Athletics usaron estadísticas que otros equipos subvaloraban para fichar jugadores baratos. Es la historia de «Moneyball».

Aire · Valle de Aburrá

En un proyecto final de curso que hice en equipo, con datos del SIATA, un modelo Random Forest anticipó 47 de los 56 días de aire dañino del conjunto de prueba: el 84 %.

LO QUE TIENEN EN COMÚN

Una pregunta clara, datos confiables y una forma sencilla de mostrar la respuesta.

Basura entra, basura sale: un error cambia la conclusión

BLOQUE 1 · POR QUÉ LIMPIAR

42,5 min

promedio real de cuatro viajes: 35, 40, 45 y 50 min

155 min

el mismo promedio si el 50 se digita como 500

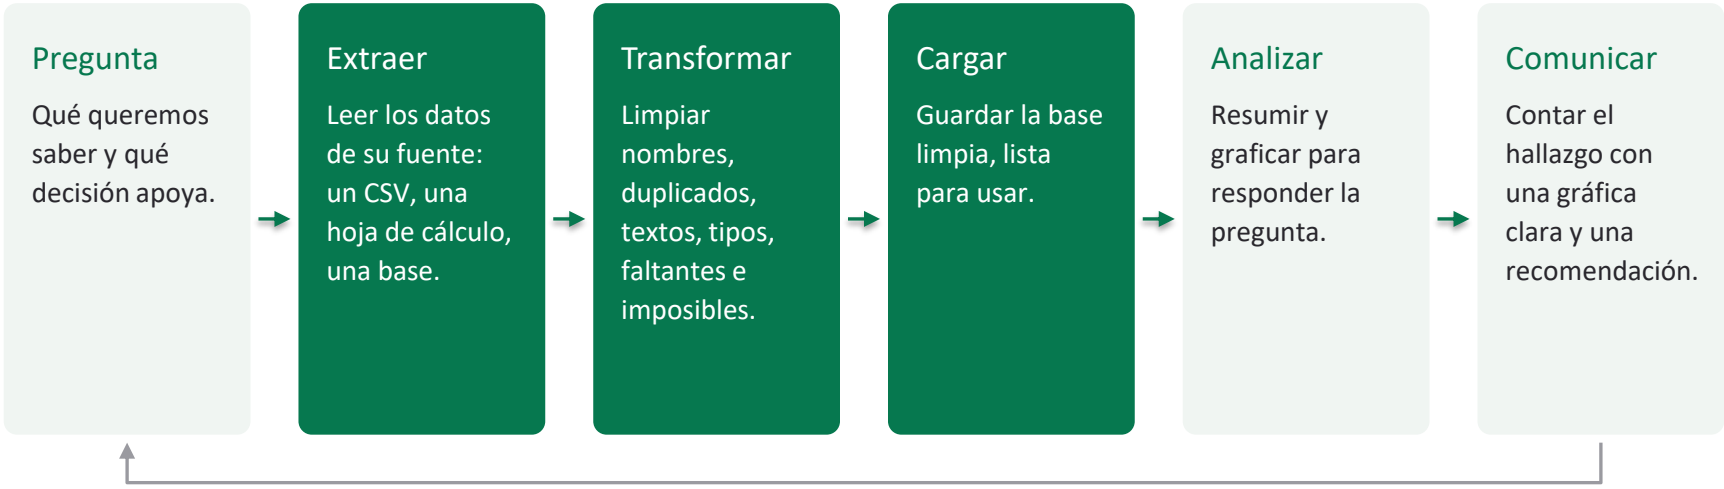
2 en vez de 1

municipios que cuenta pandas si aparecen «Medellín» y «medellin»

Un solo cero de más cambia la conclusión de «menos de una hora» a «más de dos horas y media». Si los datos están mal, el análisis más elegante da una respuesta equivocada: por eso en el taller limpiamos antes de graficar.

El análisis es un ciclo; en el taller recorremos el ETL

BLOQUE 1 · EL CICLO DEL ANÁLISIS



Extraer, Transformar y Cargar forman el ETL (por sus siglas en inglés): es lo que haremos en el taller con «Pan de Datos».

El tipo de variable decide qué gráfica usar

BLOQUE 1 · TIPOS DE VARIABLES

Tipo	Qué es	Ejemplo en «Pan de Datos»	Gráfica típica
Numérica continua	Medición que admite decimales	Distancia del domicilio: 2,5 km	Histograma, dispersión, caja
Numérica discreta	Conteo con números enteros	Unidades pedidas: de 1 a 6	Barras o histograma
Categórica nominal	Grupos sin orden	Municipio, producto, método de pago	Barras
Categórica ordinal	Grupos con un orden natural	Calificación del cliente: de 1 a 5	Barras en su orden
Fecha	Momento en el tiempo	Fecha del pedido: 14/03/2025	Líneas

«Pan de Datos» es una panadería ficticia del Valle de Aburrá: sus datos son sintéticos, creados para este curso.

Cada gráfica responde una pregunta distinta

BLOQUE 2 · TIPOS DE GRÁFICAS

Si la pregunta es…	Gráfica	Variables que necesita
¿Qué grupo tiene más y cuál menos?	Barras	Una categórica y un conteo o total
¿Cómo cambia algo con el tiempo?	Líneas	Una fecha y una numérica
¿Cómo se reparten los valores? ¿Dónde se concentran?	Histograma	Una numérica
¿Se mueven juntas dos medidas?	Dispersión	Dos numéricas
¿Cómo se comparan el centro y los extremos entre grupos?	Caja y bigotes	Una numérica y una categórica

Primero la pregunta, después la gráfica: la misma base puede necesitar cinco gráficas distintas.

Barras: comparar cantidades entre categorías

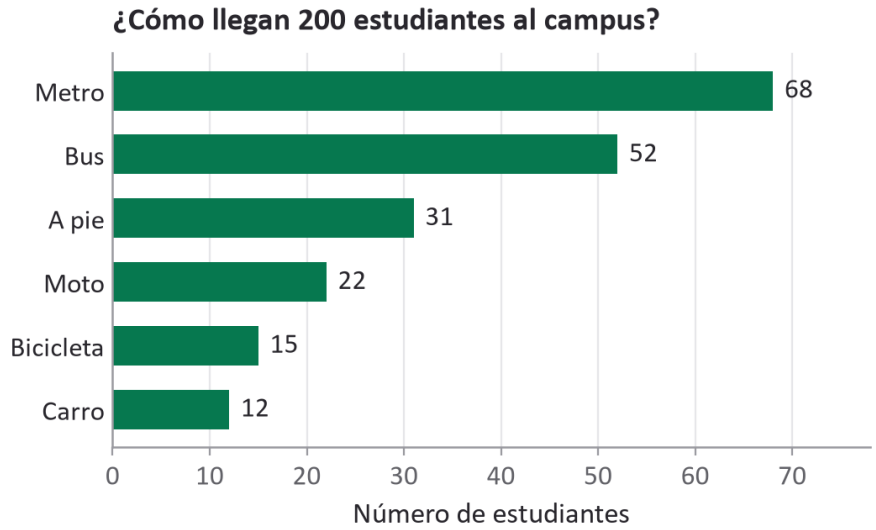
BLOQUE 2 · TIPOS DE GRÁFICAS

Responde: ¿qué grupo tiene más y cuál menos? Compara cantidades entre categorías.

Cómo se lee: 1) ver qué cuenta el eje; 2) comparar el largo de las barras; 3) ubicar la mayor y la menor.

Error típico: empezar el eje en un valor distinto de cero: el largo deja de ser proporcional al valor.

Consejo: ordenar de mayor a menor y usar barras horizontales si los nombres son largos.



Datos ilustrativos, no reales: encuesta ficticia a 200 estudiantes.

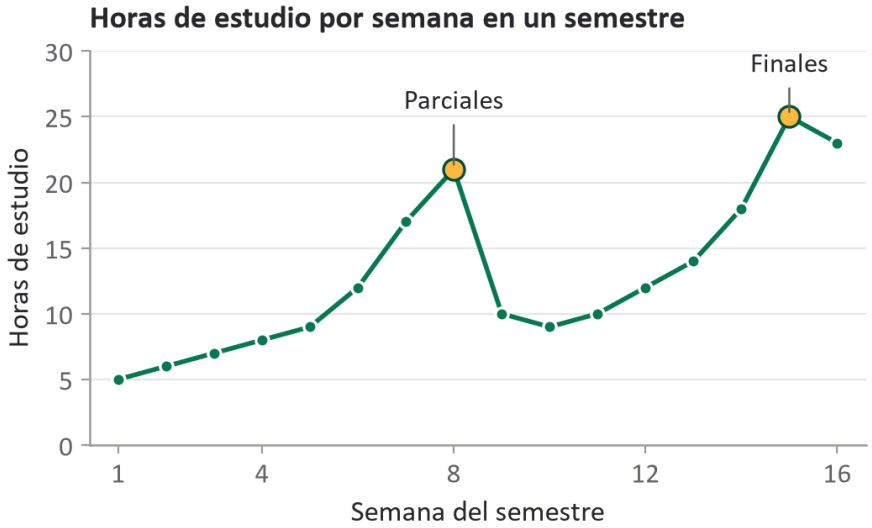
Líneas: ver cómo cambia algo en el tiempo

BLOQUE 2 · TIPOS DE GRÁFICAS

Responde: ¿cómo cambia una medida con el tiempo? ¿Sube, baja o se repite en ciclos?

Cómo se lee: 1) el tiempo va en el eje horizontal; 2) seguir la pendiente; 3) buscar picos, valles y ciclos.

Error típico: unir con una línea categorías sin orden, como carreras o municipios: la línea inventa una tendencia.



Datos ilustrativos, no reales: un estudiante ficticio durante un semestre de 16 semanas.

Histograma: ver cómo se reparten los valores

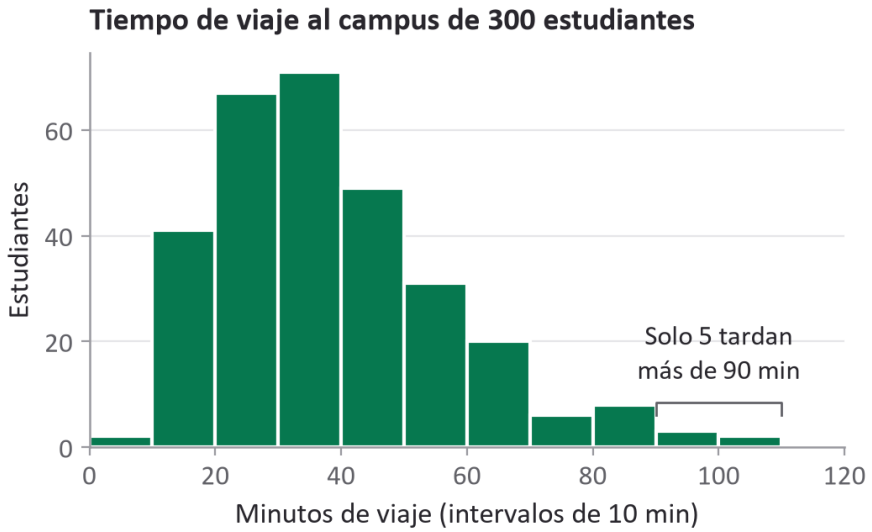
B L O Q U E 2 · T I P O S D E G R Á F I C A S

Responde: ¿cómo se reparten los valores de una variable numérica? ¿Dónde se concentran?

Cómo se lee: 1) cada barra es un intervalo de 10 min; 2) su altura cuenta cuántos caen ahí; 3) mirar la forma y la cola.

Histograma vs. barras: las barras comparan categorías; el histograma corta una variable numérica en intervalos que se tocan.

Error típico: elegir mal los intervalos (bins): muy pocos esconden la forma; demasiados la vuelven ruido.



Datos ilustrativos, no reales: 300 estudiantes ficticios, en intervalos de 10 minutos.

Dispersión: ver si dos variables se mueven juntas

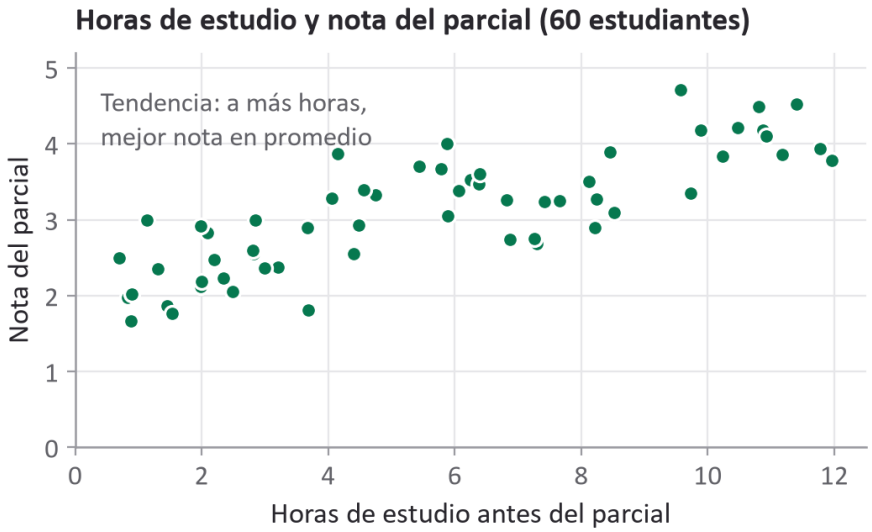
BLOQUE 2 · TIPOS DE GRÁFICAS

Responde: ¿se mueven juntas dos variables numéricas? Cuando una sube, ¿la otra también?

Cómo se lee: 1) cada punto es una observación; 2) ver si la nube sube, baja o no tiene forma; 3) revisar puntos lejanos.

Correlación no es causalidad: que dos variables suban juntas no prueba que una cause la otra; puede haber una tercera detrás.

Error típico: concluir una causa mirando la nube, o borrar los puntos lejanos sin revisarlos.



Datos ilustrativos, no reales: 60 estudiantes ficticios; cada punto es un estudiante.

Caja y bigotes: la mitad central y los extremos

BLOQUE 2 · TIPOS DE GRÁFICAS

Responde: ¿dónde está la mitad central de los datos y qué tan dispersos están? Ideal para comparar grupos.

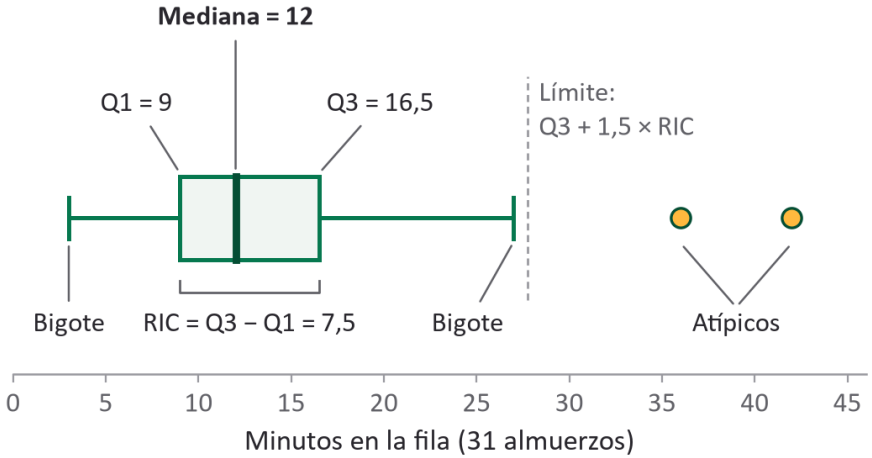
Mediana: la línea dentro de la caja (aquí, más gruesa); la mitad de los datos queda por debajo y la otra mitad por encima.

Caja (Q1 a Q3): Q1 deja abajo el 25 % de los datos y Q3 el 75 %; la caja guarda el 50 % central.

Bigotes y atípicos: RIC = Q3 − Q1. Los bigotes llegan al último dato a menos de 1,5 × RIC de la caja; más allá, atípicos.

Error típico: borrar todo atípico como si fuera un error: puede ser un dato real, como un día de aguacero.

Anatomía de una caja: minutos de fila en la cafetería



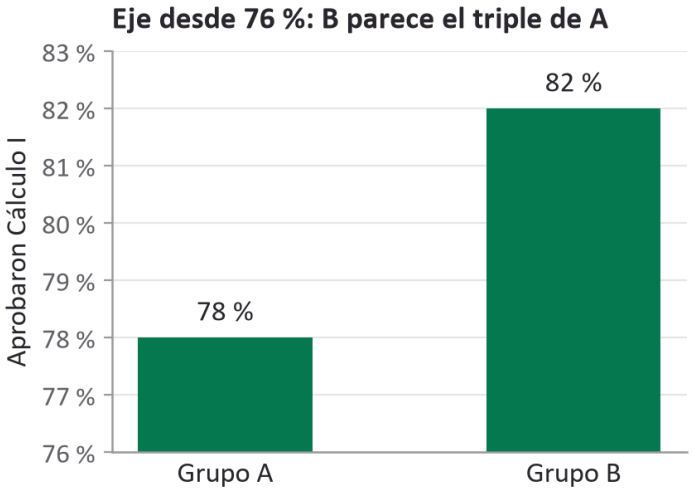
Datos ilustrativos, no reales: 31 almuerzos ficticios. Límite superior: 16,5 + 1,5 × 7,5 = 27,75 min.

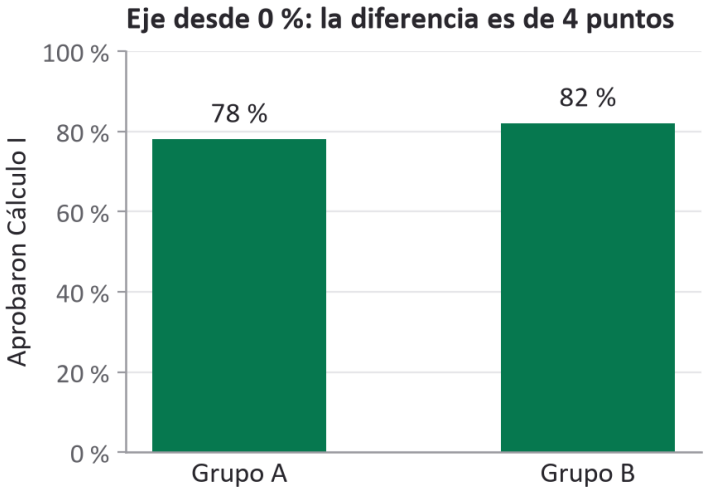
Los mismos datos, dos historias: cuidado con el eje

BLOQUE 2 · GRÁFICAS QUE ENGAÑAN

Mismos datos: A aprobó 78 % y B 82 %. Si el eje empieza en 76 %, la barra de B mide el triple que la de A.

Regla: en barras, el eje empieza en cero. Ojo también con tortas de muchas tajadas: mejor barras ordenadas.





Datos ilustrativos, no reales: porcentaje de aprobación de dos grupos ficticios de Cálculo I.

Seis preguntas para leer cualquier gráfica

BLOQUE 2 · CÓMO LEER UNA GRÁFICA

1. **Título.** ¿Dice qué se muestra, de quién y cuándo?
2. **Ejes y unidades.** ¿Qué mide cada eje y en qué unidad: minutos, pesos, porcentaje?
3. **Escala.** ¿Empieza en cero? ¿Es la misma en las gráficas que se comparan?
4. **Fuente.** ¿De dónde salen los datos y cuántos son? ¿Son reales o de ejemplo?
5. **¿Qué pregunta responde?** Si no se puede decir en una frase, la gráfica no está clara.
6. **¿Qué decisión sugiere?** ¿Qué haría distinto alguien que la mira? Ahí está su valor.

Taller: de la base sucia a la base limpia

BLOQUE 3 · TALLER ETL

35 minutos en Google Colab: leer el archivo, corregir siete errores y guardar la base lista para analizar.

«Pan de Datos»: 1.250 registros de 2025 con errores sembrados

BLOQUE 3 · EL CASO

1.250

filas en el archivo sucio, de pedidos a domicilio de 2025 (40 están repetidas)

11

columnas: fecha, municipio, producto, precio, pago, distancia, tiempo…

7

tipos de error para corregir, además de leer bien el archivo

1.180

pedidos que deben quedar al final: así se comprueba la limpieza

«Pan de Datos» es una panadería ficticia con domicilios en Medellín, Bello, Itagüí, Envigado y Sabaneta. Los datos son sintéticos: se crearon para este curso y no son cifras reales.

Once columnas: siete traen errores en sus valores

BLOQUE 3 · LA BASE

Encabezado en el CSV	Qué guarda	Ejemplo del archivo	Problema
`ID Pedido`	Número del pedido	`1001`	—
`' Fecha'`	Día del pedido	`03/01/2025`	Es texto, no fecha
`'Municipio '`	Municipio de entrega	`medellin`	19 formas de escribir 5
`PRODUCTO`	Uno de 8 productos	`Pan de bono`	—
`Cantidad`	Unidades, de 1 a 6	`5`	—
`Precio Unitario`	Precio de una unidad	`$2.800`	Texto con $ y punto; 12 vacíos
`Metodo Pago`	Efectivo, Nequi, Tarjeta o Daviplata	`NEQUI`	14 variantes; 36 vacíos
`Distancia KM`	Kilómetros recorridos	`7,1`	—
`Tiempo Entrega`	Minutos hasta entregar	`64`	Imposibles: -15, 0, 999
`Edad Cliente`	Edad en años	`23`	60 vacíos
`Calificacion`	Nota del cliente, de 1 a 5	`4`	Imposibles: 0, 10, 45

Además: 40 filas repetidas (paso 2), coma decimal en Distancia KM (paso E) y encabezados con espacios o mayúsculas (paso 1).

Prepara tu Colab en tres minutos

BLOQUE 3 · MANOS A LA OBRA

1. **Descarga los dos archivos.** `taller_estudiante.ipynb` y `domicilios_sucio.csv`, de la carpeta «taller» del enlace: `[enlace del taller]`

2. **Abre Colab.** Entra a `colab.research.google.com` con tu cuenta de Google.

3. **Sube el cuaderno.** Archivo → Subir cuaderno → `taller_estudiante.ipynb`.

4. **Sube los datos.** Ícono de carpeta (Archivos) en la barra izquierda → arrastra `domicilios_sucio.csv`.

5. **Ejecuta la primera celda.** `import pandas as pd` con Shift + Enter. Si no sale error, estás listo.

El taller sigue el ETL: extraer, transformar y cargar

BLOQUE 3 · MAPA DEL TALLER

E · Extraer

Leer el CSV con separador ; y coma decimal.

`read_csv()`
`shape`

→

T · Pasos 1 a 3

Nombres de columnas, filas duplicadas y texto inconsistente.

`str.strip()`
`drop_duplicates()`

→

T · Pasos 4 y 5

Números y fechas que llegaron como texto.

`to_numeric()`
`to_datetime()`

→

T · Pasos 6 y 7

Datos faltantes y valores imposibles.

`fillna()`
`between()`

→

L · Cargar

Revisar la base limpia y guardarla en un archivo nuevo.

`info()`
`to_csv()`

Cada paso tiene el mismo ritmo: diagnosticar con un método, corregir y comprobar.

Sin sep=';', todo el archivo cae en una sola columna

BLOQUE 3 · PASO E · EXTRAER

Problema: El archivo separa con `;` y usa coma decimal, como Excel en Colombia. `pd.read_csv` sin parámetros espera comas y da `(1250, 1)`: una sola columna.

Diagnóstico: `df.head()` y `df.shape`

Método clave: `read_csv(sep=';', decimal=',')`

EJEMPLOS

```
ID Pedido; Fecha;…
1001;03/01/2025;Bello;…
7,1
```

```
df = pd.read_csv('domicilios_sucio.csv', sep=';', decimal=',')
df.head()
```

RESULTADO

`df.shape` pasa de `(1250, 1)` a `(1250, 11)`. Distancia KM ya es número (pandas la muestra como `7.1`); Precio Unitario sigue como texto.

Nombres sin espacios ni mayúsculas en una sola línea

BLOQUE 3 · PASO 1 · NOMBRES DE COLUMNAS

Problema: Los encabezados traen espacios a los lados, mayúsculas y espacios internos. Para pandas, `' Fecha'` y `'fecha'` son columnas distintas.

Diagnóstico: `df.columns`

Método clave: `str.strip().str.lower().str.replace()`

EJEMPLOS

```
' Fecha'          'Municipio '
'PRODUCTO'        'Precio Unitario'
'Metodo Pago'
```

```
df.columns = df.columns.str.strip().str.lower().str.replace(' ', '_')
df.columns
```

RESULTADO

Los 11 nombres quedan limpios: `id_pedido`, `fecha`, `municipio`, `producto`, `precio_unitario`, `metodo_pago`… `calificacion`.

40 pedidos estaban registrados dos veces

BLOQUE 3 · PASO 2 · FILAS DUPLICADAS

Problema: Hay filas idénticas, como un pedido digitado dos veces. Si no se quitan, los pedidos y las ventas se cuentan doble.

Diagnóstico: `df.duplicated().sum()`

Método clave: `drop_duplicates()`

EJEMPLOS

```
1002 · Bello · Jugo natural
1002 · Bello · Jugo natural
1013 · Itagüí · Croissant ×2
```

```
df = df.drop_duplicates()
df.shape
```

RESULTADO

`df.duplicated().sum()` da 40. Tras `drop_duplicates()`, `df.shape` pasa de `(1250, 11)` a `(1210, 11)`.

Diecinueve formas de escribir cinco municipios

BLOQUE 3 · PASO 3 · TEXTO INCONSISTENTE

Problema: `value_counts()` cuenta cada variante por aparte: medellin, MEDELLIN y ' Medellín ' parecen tres municipios. El pago tiene 14 variantes.

Diagnóstico: `df['municipio'].value_counts()`

Método clave: `str.strip().str.title() y replace()`

EJEMPLOS

medellin	MEDELLIN
' Medellín '	Itagui
'BELLO '	

```
df['municipio'] = df['municipio'].str.strip().str.title()
df['municipio'] = df['municipio'].replace({'Medellin': 'Medellín', 'Itagui': 'Itagüí'})
df['metodo_pago'] = df['metodo_pago'].str.strip().str.title()
```

RESULTADO

Municipio: de 19 variantes a 5 (Medellín 532, Envigado 206, Itagüí 176, Bello 163, Sabaneta 133). Pago: de 14 a 4.

Con «$2.800» como texto no se puede sumar

BLOQUE 3 · PASO 4 · NÚMEROS COMO TEXTO

Problema: `df.dtypes` muestra `precio_unitario` como `object`, es decir, texto, por el signo $ y el punto de miles. Un texto no se puede multiplicar.

Diagnóstico: `df.dtypes`

Método clave: `str.replace()` y `pd.to_numeric()`

EJEMPLOS

$2.800	$9.500
2.000	(vacío)

```
df['precio_unitario'] = df['precio_unitario'].str.replace('$', '')
df['precio_unitario'] = df['precio_unitario'].str.replace('.', '')
df['precio_unitario'] = pd.to_numeric(df['precio_unitario'])
```

RESULTADO

`precio_unitario` pasa de `object` a `float64`: de 2.000 a 9.500 pesos. Los 12 vacíos quedan como `NaN`, sin error.

Una fecha de verdad permite sacar el mes

BLOQUE 3 · PASO 5 · FECHAS COMO TEXTO

Problema: `fecha` llegó como texto: así no se puede sacar el mes ni ordenar en el tiempo. Tampoco existe aún el valor total de cada pedido.

Diagnóstico: `df.dtypes`

Comprobación: `df.head()`

Método clave: `pd.to_datetime(format='%d/%m/%Y')` y `dt.month`

EJEMPLOS

```
03/01/2025
13/07/2025
31/12/2025
```

```
df['fecha'] = pd.to_datetime(df['fecha'], format='%d/%m/%Y')
df['mes'] = df['fecha'].dt.month
df['total'] = df['cantidad'] * df['precio_unitario']
```

RESULTADO

`fecha` queda como `datetime64`, del 3 de enero al 31 de diciembre de 2025. Se crean `mes` y `total`: 13 columnas.

Cada dato faltante se trata distinto

BLOQUE 3 · PASO 6 · DATOS FALTANTES

Problema: `df.isna().sum()` cuenta vacíos: 36 en `metodo_pago`, 12 en `precio_unitario` (y en `total`) y 60 en `edad_cliente`. No hay una receta única.

Diagnóstico: `df.isna().sum()`

Método clave: **`fillna('Sin dato') y dropna(subset=...)`**

EJEMPLOS

`1009 · sin precio`
`1019 · sin pago`
`1016 · sin edad`

```
df['metodo_pago'] = df['metodo_pago'].fillna('Sin dato')
df = df.dropna(subset=['precio_unitario'])
df.shape
```

RESULTADO

36 pagos quedan como 'Sin dato' y salen 12 pedidos sin precio: `(1198, 13)`. La edad conserva sus 60 vacíos.

Nadie espera 999 minutos ni califica con 45

BLOQUE 3 · PASO 7 · VALORES IMPOSIBLES

Problema: `describe()` delata lo imposible: `tiempo_entrega` va de -15 a 999 minutos y la calificación llega a 0 y a 45, en una escala de 1 a 5.

Diagnóstico: `df.describe()`

Método clave: `between()`

EJEMPLOS

```
tiempo -15          tiempo 0
tiempo 999          calificación 10
calificación 45
```

```
df = df[df['tiempo_entrega'].between(1, 180)]
df = df[df['calificacion'].between(1, 5)]
df.shape
```

RESULTADO

Salen 10 tiempos y 8 calificaciones imposibles: `(1180, 13)`. Quedan tiempos de 10 a 98 min y notas de 2 a 5.

1.180 pedidos limpios, guardados en un archivo nuevo

BLOQUE 3 · PASO L · CARGAR

Problema: La base limpia solo existe en la memoria de Colab. Antes de guardarla, `info()` confirma filas, tipos y vacíos de cada columna.

Diagnóstico: `df.info()`

Método clave: `to_csv(index=False)`

EJEMPLOS

```
1.250 → 1.180 filas
11 → 13 columnas
precio: texto → número
```

```
df.info()
df.to_csv('domicilios_limpio.csv', index=False)
```

RESULTADO

`info()`: 1.180 filas y 13 columnas; solo `edad_cliente` tiene vacíos (1.120 datos). Queda guardado `domicilios_limpio.csv`.

Análisis: cinco preguntas, cinco gráficas

BLOQUE 4 · ANÁLISIS GRÁFICO

Con la base limpia, cada gráfica es una instrucción de pandas que responde una pregunta de negocio de «Pan de Datos».

Pan de bono lidera; la torta de chocolate es la última

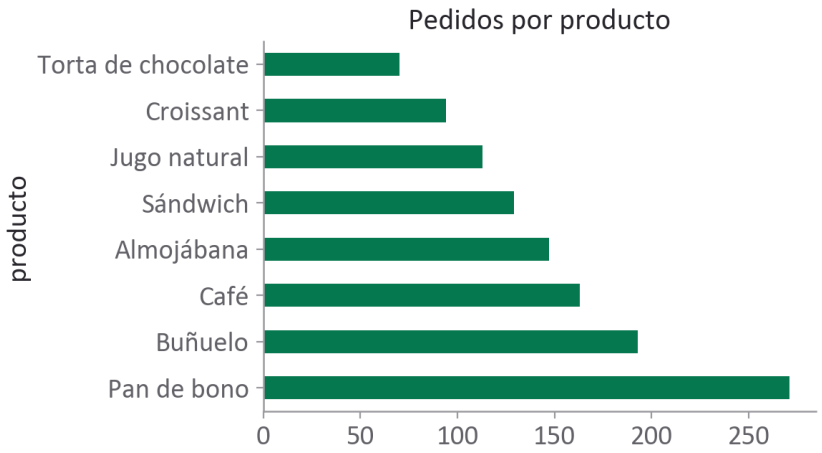
B L O Q U E 4 · G R Á F I C A 1 · B A R R A S

Datos sintéticos de «Pan de Datos»: base limpia de 1.180 pedidos

```
df['producto'].value_counts().plot(
    kind='barh', title='Pedidos por producto', color='#06784F')
```

¿Qué productos se piden más?

Pan de bono es el más pedido: 271 pedidos, 1,4 veces los 193 del Buñuelo. Torta de chocolate es la última, con 70. Ojo: el eje cuenta pedidos, no pesos.



P R E G U N T A P A R A E L G R U P O

¿El producto menos pedido es también el que menos dinero deja? ¿Cómo lo averiguarían?

Diciembre vende 2,6 veces lo que vende febrero

BLOQUE 4 · GRÁFICA 2 · LÍNEAS

Datos sintéticos de «Pan de Datos»: base limpia de 1.180 pedidos

```
df.groupby('mes')['total'].sum().plot(
    kind='line', marker='o', color='#06784F',
    title='Ventas por mes', ylabel='Pesos')
```

¿Cómo cambian las ventas durante el año?

Las ventas tocan fondo en febrero (654.800 pesos), suben en junio y julio y llegan al pico en diciembre (1.697.700). El eje no empieza en cero (en líneas se acepta, porque importa la forma), así que lean los valores; «1e6» significa millones.



PREGUNTA PARA EL GRUPO

¿Qué harían con el personal y el inventario en diciembre? ¿Y qué probarían en febrero?

Los clientes forman dos grupos de edad, no uno

B L O Q U E 4 · G R Á F I C A 3 · H I S T O G R A M A

Datos sintéticos de «Pan de Datos»: base limpia de 1.180 pedidos

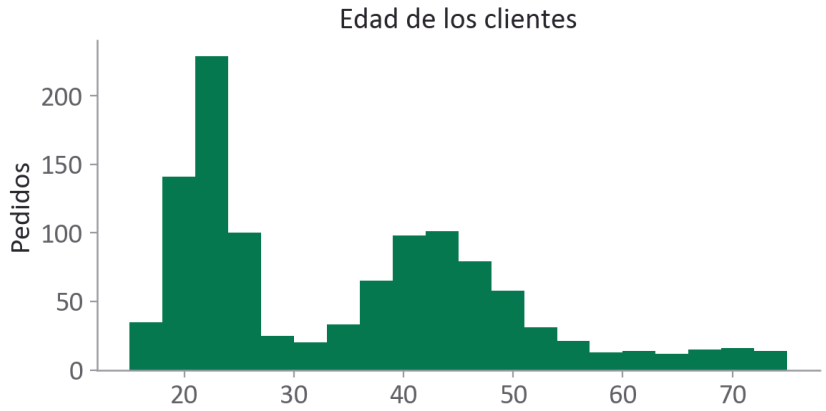
```
df['edad_cliente'].plot(
    kind='hist', bins=20, color='#06784F',
    title='Edad de los clientes', ylabel='Pedidos')
```

¿Quiénes son nuestros clientes?

La forma tiene dos jorobas: 420 pedidos de clientes de 19 a 25 años y 324 de 38 a 48, con un valle entre 29 y 35 (solo 59 pedidos). Los 60 pedidos sin edad no se cuentan.

P R E G U N T A P A R A E L G R U P O

El promedio de edad es 34,5 años. ¿Describe bien a un cliente típico?



A más distancia, más tiempo de entrega

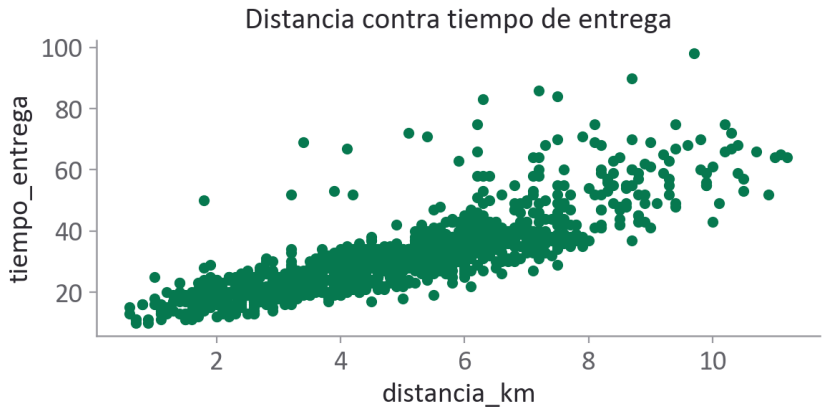
B L O Q U E 4 · G R Á F I C A 4 · D I S P E R S I Ó N

Datos sintéticos de «Pan de Datos»: base limpia de 1.180 pedidos

```
df.plot(
    kind='scatter', x='distancia_km', y='tiempo_entrega',
    title='Distancia contra tiempo de entrega', color='#06784F')
```

¿Tardamos más cuando el pedido va más lejos?

La nube sube de izquierda a derecha: con 2 km o menos la entrega tarda 17 min en mediana y con 8 km o más, 55,5 min. Los puntos muy por encima de la nube son atrasos que vale la pena revisar.



P R E G U N T A P A R A E L G R U P O

Si un cliente pide desde 10 km, ¿qué tiempo de entrega le prometerían?

Bello es el municipio más lento y el más impredecible

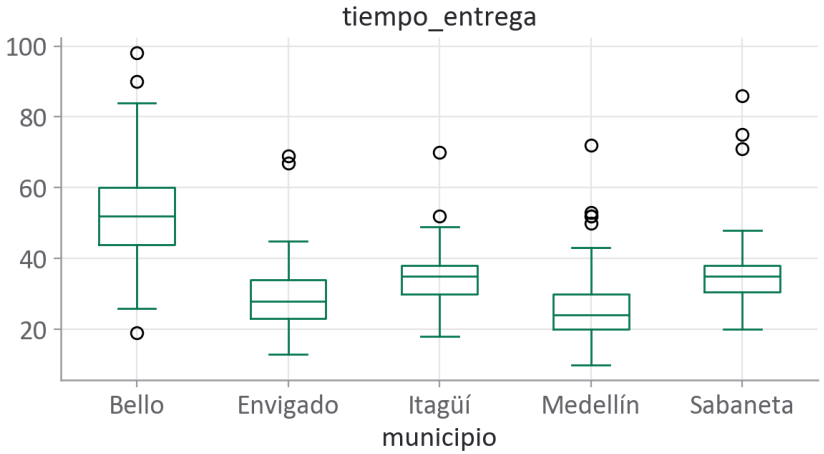
BLOQUE 4 · GRÁFICA 5 · CAJA Y BIGOTES

Datos sintéticos de «Pan de Datos»: base limpia de 1.180 pedidos

```
df.boxplot(column='tiempo_entrega', by='municipio', color='#06784F')
```

¿Dónde se demoran más los domicilios?

Bello tiene la mediana más alta (52 min; Medellín, 24) y la caja más larga (de 44 a 60 min). Los círculos son atípicos legítimos, no errores. En Colab sale además el título automático «Boxplot grouped by municipio».



PREGUNTA PARA EL GRUPO

¿Bello es lento solo porque queda más lejos? ¿Con qué datos lo comprobarían?

Cada método del taller resuelve un problema concreto

BLOQUE 5 · RESUMEN DE MÉTODOS

Método o atributo	Para qué sirve	Paso
`pd.read_csv(sep=';', decimal=',')`	Leer un CSV con punto y coma y coma decimal	E
`head() · shape · columns · dtypes · info()`	Mirar la tabla, su tamaño, sus nombres, sus tipos y sus vacíos	E a L
`columns.str.strip().str.lower().str.replace()`	Dejar nombres de columnas cómodos de escribir	1
`duplicated() · drop_duplicates()`	Contar y quitar filas repetidas	2
`value_counts()`	Contar cuántas veces aparece cada valor	3
`str.strip().str.title() · replace()`	Unificar un texto escrito de varias formas	3
`str.replace() · pd.to_numeric()`	Convertir «$2.800» en el número 2800	4
`pd.to_datetime() · dt.month`	Convertir texto en fecha y sacar el mes	5
`isna() · fillna() · dropna()`	Contar, rellenar o quitar datos faltantes	6
`describe() · between()`	Ver mínimos y máximos; quedarse con un rango válido	7
`to_csv(index=False)`	Guardar la base limpia en un archivo	L
`groupby() · plot(kind=...)`	Resumir por grupos y graficar	Análisis

Cuaderno de solución, para repasar en casa: carpeta «solución» de `[enlace del taller]`

Seis revisiones antes de analizar cualquier base

BLOQUE 5 · LISTA DE CHEQUEO

1. **¿Se leyó bien?** `head()` y `shape`: ¿salen las columnas que esperabas?
2. **¿Los nombres son cómodos?** Sin espacios ni mayúsculas: `strip`, `lower` y `replace`.
3. **¿Hay filas repetidas?** `duplicated().sum()` antes de contar o sumar.
4. **¿Cada columna tiene su tipo?** `dtypes`: los números como número y las fechas como fecha.
5. **¿Qué falta y qué hago con eso?** `isna().sum()` y decidir por columna: rellenar, quitar o dejar.
6. **¿Hay texto inconsistente o valores imposibles?** `value_counts()` para categorías; `describe()` para mínimos y máximos.

Gracias

PREGUNTAS · PARA SEGUIR APRENDIENDO

Documentación de pandas: pandas.pydata.org/docs

Kaggle Learn, cursos gratuitos de pandas y visualización: kaggle.com/learn

Google Colab, para practicar desde el navegador: colab.research.google.com

Reto para casa, al final del cuaderno: ¿califican peor cuando el domicilio tarda más?

Andrés David Galeano Quintero · Facultad de Minas, Sede Medellín

Universidad Nacional de Colombia